

# Trabalho de Análise de Redes Sociais e Análise de Texto

Professor Fernando Ferreira 17/12/2019

# Agenda

Buscaremos notícias relacionadas ao Banco BNDES.

Para tal acessaremos o portal de notícias G1.

As etapas dessa atividade serão:

- · Acessaremos os links sobre as notícias do BNDES presentes na página de busca no portal;
- · Acessaremos cada um dos links e recuperaremos as notícias;
- · Analisaremos as notícias usando o pacote SpacyR;
- · Criaremos uma lista de arestas para exportar para o Gephi;
- · Criaremos uma visualização no Gephi e analisaremos as principais estatísticas para finalizar a tarefa.



#### Pacotes Necessários

Os pacotes que são importantes para a realização do trabalho:

```
set.seed(123)
#install the necessary packages
list.of.packages <- c('rvest',</pre>
                       'stringr',
                       'tidyverse',
                       'tm',
                       'igraph',
                       'wordcloud',
                       'urltools',
                       'spacyr',
                       'gtools')
new.packages <-
   list.of.packages[!(list.of.packages %in% installed.packages()[, "Package"])]
if (length(new.packages))
    install.packages(new.packages, dependencies = TRUE)
for (package in list.of.packages){
    library(package, character.only = TRUE)
}
```



### Acessar as Páginas

Criaremos uma função auxiliar para acessar os links

```
scrape_post_links <- function(site) {
    # scrape HTML from input site
    source_html <- read_html(site)
    # grab the title attributes from link (anchor)
    # tags within H2 header tags
    links <- source_html %>%
        html_nodes("div.widget--info__text-container") %>%
        html_nodes("a") %>%
        html_attr("href")
    # filter out any titles that are NA (where no title was found)
    links <- links[!is.na(links)]
    # return vector of titles
    return(links)
}</pre>
```



# Fazer iterações em 20 páginas

```
root <- "https://gl.globo.com/busca/?q=BNDES"

# get each webpage URL we need
all_pages <- c(root, paste0(root, "&page=", 1:20))
# use our function to scrape the title of each post
all_links <- lapply(all_pages, scrape_post_links)

# collapse the titles into a vector
all_links <- unlist(all_links)</pre>
```



## A URL real está contida em parâmetro do link "u"

Criar uma função para extrair esses links



### Acessar de cada link



```
# convert all titles to lowercase
cleaned <- tolower(data)
# remove any numbers from the titles
cleaned <- removeNumbers(cleaned)
# remove English stopwords
cleaned <- removeWords(cleaned, c(stopwords("pt"), "bndes", "banco"))
# remove punctuation
cleaned <- removePunctuation(cleaned)
# remove spaces at the beginning and end of each title
cleaned <- str_trim(cleaned)
# convert vector of titles to a corpus</pre>
```

# Pré-processar os textos para nuvens de palavras(1/2)

```
cleaned_corpus <- Corpus(VectorSource(cleaned))
# steam each word in each title
cleaned_corpus <- tm_map(cleaned_corpus, stemDocument)
doc_object <- TermDocumentMatrix(cleaned_corpus)
doc_matrix <- as.matrix(doc_object)
# get counts of each word
counts <- sort(rowSums(doc_matrix), decreasing=TRUE)
# filter out any words that contain non-letters
counts <- counts[grepl("^[a-z]+$", names(counts))]
# create data frame from word frequency info
frame_counts <- data.frame(word = names(counts), freq = counts)</pre>
```

# Pré-processar os textos para nuvens de palavras (2/2)

# Criar a nuvem de palavras



#### Extrair todas as entidades dos textos

```
spacy initialize(model="pt core news sm")
entities <- spacy extract entity(unlist(data))</pre>
head(entities)
    doc id
                                                                    text
## 1 text1
                                                       A Renova Energia
     text1 2ª Vara de Falências e Recuperações Judiciais de São Paulo
## 3
     t.ext.1
## 4 text1
                                                                      R$
## 5 text1
                  Banco Nacional de Desenvolvimento Econômico e Social
## 6 text1
                                                                   BNDES
     ent type start id length
## 1
         MISC
                     2
                            3
## 2
         MISC
                    19
                           10
## 3
         LOC
                    44
                            1
## 4
         PER
                    51
                            1
## 5
                    57
                            7
          ORG
## 6
          ORG
                    65
                            1
```



### Criar lista de adjacência

Criaremos a lista de adjacência onde cada aresta define a coocorrência de duas entidades em um texto

```
# group entities by document
filtered entities <- subset(entities, entities["ent type"] == "ORG" |
                                       entities["ent type"] == "PER" )
edges <- filtered entities %>%
         group by(doc id) %>%
         summarise(entities = paste(text, collapse = ","))
# remove duplicated for the same document
edges <- lapply(str split(edges$entities, ","),</pre>
                function(t) {unique(unlist(t))})
# Auxiliary functions for creating adjancht
get adjacent list <- function(edge list) {</pre>
    adjacent matrix <- combinations(length(edge list),</pre>
                                     2, edge list)
    return(adjacent matrix)
adjacent matrix <- edges %>%
                   lapply(get adjacent list) %>%
                   reduce(rbind)
```



# Criar Objeto Grafo que será exportado por Gephi

